«Суть» — работа с Docker

Установка, запуск, переключение вариантов, обновление, резервная копия и частые проблемы · 27 октября 2026

1. Как устроено

Где	Что
Контейнер `sut`	сервер, сайт, распознавание речи (Whisper), поиск (bge-m3, reranker), скачивание видео (yt-dlp, ffmpeg)
Том Docker `sut-data` → `/data`	база лекций, видео, модели (~9 ГБ), вход в YouTube — переживает пересоздание контейнера и смену варианта
Сам компьютер	Ollama с моделью `qwen-instruct:4b` — конспекты, чат, перевод. Контейнер обращается к ней по сети

Два варианта образа, данные у них общие, работает один контейнер:

	Только процессор — `sut:cpu`	С видеокартой NVIDIA — `sut:gpu`
Размер образа	~3 ГБ	~13 ГБ
Поиск	3–6 с	0,2 с
Лекция 4–5 мин целиком	~3 мин	~2,7 мин
Часовая лекция: распознавание	15–60 мин	~10–15 мин

2. Первый запуск

1. **Docker Desktop**: https://www.docker.com/products/docker-desktop/ — установить с WSL 2, перезагрузить ПК, если попросит, запустить и дождаться «Engine running». В настройках (General) включить «Start Docker Desktop when you sign in».
2. **Ollama**: https://ollama.com/download — установить, в трее появится значок ламы. Модель качать не нужно: контейнер сам передаст её Ollama.
3. **Только для видеокарты**: свежий драйвер NVIDIA. Проверка: `nvidia-smi` показывает видеокарту.
4. **Код**: распаковать архив с исходниками (папка `sut`) или `git clone https://github.com/WiverHome/sut.git`. Открыть PowerShell в этой папке.
5. **Собрать и запустить** — одну из команд:

   ```
   # с видеокартой NVIDIA
   docker compose -f docker-compose.yml -f docker-compose.gpu.yml up -d --build

   # без видеокарты
   docker compose up -d --build
   ```

   Сборка с видеокартой качает ~4,5 ГБ (на проверке — 35 мин), без неё ~1 ГБ. В конце — `Container sut Started`.

6. **Дождаться моделей** (~9 ГБ, на проверке — около 26 мин):

   ```
   docker compose logs -f sut
   ```

   Готово, когда появятся строки «Модель qwen-instruct:4b подключена к Ollama» и «Uvicorn running». Выйти из журнала — `Ctrl+C`, контейнер продолжит работать. Если загрузка прервётся — после перезапуска продолжится с того же места.
7. Открыть **http://127.0.0.1:8000**.

> Если сборка оборвалась с `TLS handshake timeout` или `connection reset` — это сбой сети. Повторите ту же команду: уже скачанное не перекачивается.

2a. Запуск из готового образа — без сборки

В архиве лежит готовый образ для процессора `sut-cpu-image.tar` (~3 ГБ после загрузки). С ним не нужно ничего собирать и качать PyTorch — только модели при первом запуске.

1. Установить Docker Desktop и Ollama (шаги 1–2 выше).
2. Распаковать архив, открыть PowerShell в папке `01 Исходный код\sut`.
3. Загрузить образ (1–3 минуты):

   ```
   docker load -i "..\..\04 Docker-образ\sut-cpu-image.tar"
   ```

   В конце — `Loaded image: sut:cpu`.
4. Запустить **без** `--build`:

   ```
   docker compose up -d
   ```

5. Дождаться моделей (шаг 6 выше) и открыть **http://127.0.0.1:8000**.

Образ с видеокартой в архив не входит (13 ГБ) — на ПК с NVIDIA его собирают командой из шага 5.

3. Повседневные команды

Все команды — в PowerShell, в папке проекта.

Что сделать	Команда
Остановить	`docker compose stop`
Запустить снова	`docker compose start`
Перезапустить (освободить видеопамять)	`docker restart sut`
Журнал	`docker compose logs -f sut`
Состояние и память контейнера	`docker ps` · `docker stats --no-stream`
Перейти на вариант с видеокартой	`docker compose -f docker-compose.yml -f docker-compose.gpu.yml up -d`
Перейти на вариант для процессора	`docker compose up -d`
Видит ли контейнер видеокарту	`docker compose exec sut python -c "import torch; print(torch.cuda.is_available())"` — должно быть `True`
Удалить контейнер, данные оставить	`docker compose down`
Удалить всё вместе с лекциями и моделями	`docker compose down -v`

После перезагрузки ПК всё поднимается само: Docker Desktop и Ollama в автозагрузке, контейнер запускается вместе с Docker (`restart: unless-stopped`). Если сайт не открывается — запустите Docker Desktop из меню «Пуск».

4. Обновление

```
git pull
docker compose -f docker-compose.yml -f docker-compose.gpu.yml up -d --build
```

Для варианта без видеокарты — `docker compose up -d --build` . Обновляются только изменившиеся слои: обычно это 1–3 минуты. Лекции и модели не трогаются.

5. Резервная копия и перенос лекций

Сохранить (база, видео, модели, вход в YouTube) в файл `sut-data.tgz` в папке проекта:

```
docker compose stop
docker compose run --rm --no-deps --entrypoint sh -v "${PWD}:/backup" sut -c "tar czf /backup/sut-data.tgz -C /data ."
docker compose start
```

Восстановить на другом ПК — после шага 5 «Собрать и запустить», файл `sut-data.tgz` в папке проекта:

```
docker compose stop
docker compose run --rm --no-deps --entrypoint sh -v "${PWD}:/backup" sut -c "tar xzf /backup/sut-data.tgz -C /data"
docker compose start
```

В архиве лежит вход в YouTube (`youtube_cookies.txt`), если он был настроен, — передавайте его только на свой компьютер.

6. Настройки

Файл `.env` рядом с `docker-compose.yml` , после правки — `docker compose up -d` :

Переменная	По умолчанию	Что это
`SUT_PORT`	8000	порт сайта
`SUT_BIND`	127.0.0.1	`0.0.0.0` — открыть для локальной сети (пароля в сервисе нет — в интернет так не открывать)
`SUT_OLLAMA`	http://host.docker.internal:11434	адрес Ollama
`SUT_LLM`	qwen-instruct:4b	модель Ollama
`SUT_DEVICE`	auto	`cpu` — не использовать видеокарту

7. Видеокарта на 6 ГБ: что важно знать

- Распознавание, модели поиска и языковая модель вместе едва помещаются. Пока распознаётся новая лекция, вопросы в чате отвечает модель на процессоре: ответ дольше (30–45 с вместо 7 с), зато распознавание не останавливается.
- Перед показом закройте лишние программы (игры, браузеры с видео) и выполните `docker restart sut` .
- Если распознавание вдруг идёт в разы медленнее обычного — `docker restart sut` : обработка продолжится с того же шага.
- WSL (виртуальная машина Docker) со временем копит кэш файлов и занимает много ОЗУ. Освободить без остановки сайта:

```
wsl -d docker-desktop -u root sh -c "sync; echo 3 > /proc/sys/vm/drop_caches"
```

8. Если что-то не так

Что видно	Что делать
`could not select device driver "nvidia"`	Docker не видит видеокарту: обновите драйвер NVIDIA или используйте вариант без видеокарты.
`port is already allocated`	Порт 8000 занят: в `.env` добавьте `SUT_PORT=8001`, откройте http://127.0.0.1:8001.
В шапке сайта «Без конспектов»	Контейнер не видит Ollama: запустите её (значок в трее), затем `docker restart sut`.
YouTube: «подтвердите, что вы не робот»	Перенесите вход в YouTube резервной копией (раздел 5) или выгрузите его из браузера — DOCKER.md, раздел «Вход в YouTube».
Лекция долго стоит «В очереди»	`docker restart sut` — обработка продолжится с того же шага.
Сайт не открывается после перезагрузки	Запустите Docker Desktop; контейнер поднимется сам через ~30 с.
Мало места на диске	Кэш сборки Docker: `docker builder prune` (освобождает до ~16 ГБ; следующая сборка будет дольше).