«Суть» — развёртывание с нуля

Отчёт о проверке чистой установки и подробная инструкция · 27 октября 2026

1. Итог проверки

Чистая установка по инструкции работает. С кодом прямо из GitHub, без готовых файлов на ПК, сервис поднялся в обоих вариантах. Лекция с RuTube обработалась целиком, поиск нашёл нужное место по-русски и по-английски, ссылки YouTube скачиваются без входа в аккаунт, языковая модель сама передалась в пустую Ollama.

Сколько времени занимает	С видеокартой	Только процессор
Развернуть с нуля до работающего сайта (при скорости интернета 1–15 МБ/с)	**≈ 61 мин**	**≈ 30–35 мин***
Обработать лекцию 4–5 минут: скачать, распознать, оглавление, конспект	**2 мин 41 с**	**2 мин 55 с**
Перевод расшифровки на второй язык (после конспекта)	**+23 с**	**+21 с**
Поиск (обычный запрос / самый первый после запуска)	**0,1 с / 2,2 с**	**3,4–3,9 с / 14,5 с**

* Оценка: образ для процессора качает ~1 ГБ вместо ~4,5 ГБ, модели те же ~8,7 ГБ. В проверке он собирался после варианта с видеокартой и взял базовые образы и интерфейс из кэша — 3,7 мин.

2. Как проверяли

Компьютер: ноутбук Intel Core i5-13500H, 16 ГБ памяти, NVIDIA GeForce RTX 4050 Laptop (6 ГБ), Windows 11, Docker Desktop 29.8, Ollama 0.40.

Что удалили перед проверкой: все образы «Сути» и базовые образы Python и Node, кэш сборки Docker (18,7 ГБ), том с моделями, базой и видео, языковую модель в Ollama. Сами Docker Desktop и Ollama остались установлены — время их установки не замерялось.

Что делали: скачали код с GitHub в новую папку и выполнили шаги инструкции из раздела 4 — команду сборки и запуска, ожидание моделей, добавление лекции. Время каждого этапа записывалось автоматически.

Вариант с видеокартой — по этапам

Этап	Время	Что происходило
Скачать код с GitHub	**2 с**	git clone
Собрать образ и запустить контейнер	**34 мин 34 с**	Скачивание ~4,5 ГБ: PyTorch с библиотеками NVIDIA (cuDNN 658 МБ, PyTorch 820 МБ и др.), зависимости программы, сборка интерфейса, упаковка образа 12,8 ГБ. Скорость сети 1–8 МБ/с.
Скачать модели	**≈ 26 мин**	~8,7 ГБ: Whisper 1,6 ГБ, bge-m3 2,3 ГБ, reranker 2,3 ГБ, Qwen 2,5 ГБ. Загрузка прерывалась выключением ПК и продолжилась с того же места. Скорость 4–15 МБ/с.
Передать языковую модель в Ollama	**< 1 мин**	Контейнер сам подключил Qwen к пустой Ollama и удалил свою копию файла.
Итого до работающего сайта	**≈ 61 мин**	**Без учёта паузы на выключение ПК**
Первая лекция (RuTube, 4 мин)	**2 мин 41 с**	Скачивание 6 с, распознавание ~1,5 мин (первый запуск: Whisper грузится с диска), конспект ~1 мин. Итог: конспект 861 знак, 4 раздела, 10 терминов. Перевод — ещё 23 с.

Вариант для процессора

Этап	Время	Что происходило
Собрать образ и запустить	**3 мин 42 с**	PyTorch без CUDA и зависимости программы; базовые образы и интерфейс — из кэша. Образ 2,9 ГБ.
Готовность поиска после запуска	**12 с**	Модели уже лежали в общем томе.
Лекция (RuTube, 5,3 мин)	**2 мин 55 с**	Скачивание 9 с, распознавание ~2 мин, индекс 7 с, конспект ~45 с. Перевод — ещё 21 с.

Конспект, чат и перевод в обоих вариантах делает Ollama на самом ПК, и она пользуется видеокартой. Поэтому эти этапы занимают одинаковое время, а разница — в распознавании речи и поиске.

Что ещё проверено

- Ссылки YouTube: видео отдаётся и без входа в аккаунт (в образе Node 24; с Node 20 YouTube отдавал только картинки-превью — исправлено 26.10).
- Переключение между вариантами одной командой, лекции и модели при этом общие.
- Сайт https://sut.foreio.tech после перезагрузки ПК: сторож туннеля сам запустился при входе в Windows и поднял Ollama.

Что нашли и исправили

- **Docker Desktop не запустился сам после перезагрузки**, хотя стоит в автозагрузке, — пришлось запускать вручную. Сторож сайта теперь запускает и Docker Desktop, если его нет.

- Самый первый запрос поиска после запуска медленнее (2,2 с на видеокарте, 14,5 с на процессоре) — модели прогреваются. Дальше — 0,1 с и 3,5 с.

Что не проверено

- Другой компьютер с другим железом: проверка шла на этом же ПК после удаления всех данных «Сути».
- Установка самих Docker Desktop и Ollama — они уже были установлены.
- Linux и macOS.
- Вариант только для процессора на совсем пустом ПК (без кэша базовых образов) — время дано оценкой.

Сколько ждать на другом ПК

Скорость интернета	С видеокартой (~13 ГБ скачать)	Только процессор (~10 ГБ)
5 МБ/с (40 Мбит/с)	≈ 50–60 мин	≈ 35–40 мин
12 МБ/с (100 Мбит/с)	≈ 25–30 мин	≈ 15–20 мин
60 МБ/с (500 Мбит/с)	≈ 10–15 мин	≈ 7–10 мин

Плюс 10–20 минут на установку Docker Desktop и Ollama, если их ещё нет. Время упаковки образа (2–4 мин) от интернета не зависит.

3. Что нужно на компьютере

Что	Требование
Система	Windows 10/11, 64-битная (Linux и macOS — см. DOCKER.md в репозитории)
Память	от 16 ГБ
Место на диске	~30 ГБ: образ 3 или 13 ГБ, модели ~9 ГБ, временные файлы сборки, видео лекций
Видеокарта	по желанию: NVIDIA от 6 ГБ — в разы быстрее; без неё всё работает на процессоре
Интернет	только при первом запуске — скачать образ и модели; дальше работает без интернета (кроме ссылок YouTube/RuTube)

4. Пошаговая инструкция (Windows)

Шаг 1. Установить Docker Desktop

1. Скачайте Docker Desktop: `https://www.docker.com/products/docker-desktop/` и запустите установщик. Оставьте галочку **Use WSL 2**. Windows спросит разрешение администратора — нажмите «Да».
2. Если установщик попросит — перезагрузите ПК.
3. Запустите Docker Desktop, примите условия и дождитесь зелёной надписи **Engine running** внизу слева.
4. В настройках (шестерёнка → General) включите **Start Docker Desktop when you sign in**.

Проверка — откройте PowerShell (Пуск → набрать «PowerShell») и введите:

```
docker --version
```

Должно получиться `Docker version 2x.x.x`.

Шаг 2. Установить Ollama

1. Скачайте с `https://ollama.com/download` и установите.
2. В трее (справа внизу) появится значок ламы. Ollama сама добавляет себя в автозагрузку.

Проверка:

```
ollama --version
```

Языковую модель отдельно качать не нужно: при первом запуске контейнер скачает её (~2,5 ГБ) и сам передаст в Ollama.

Шаг 3. Только для видеокарты NVIDIA — драйвер

Обновите драйвер NVIDIA: `https://www.nvidia.com/drivers`. Проверка:

```
nvidia-smi
```

Должна появиться таблица с названием видеокарты. Без видеокарты этот шаг пропустите.

Шаг 4. Получить код

Вариант А — через git (нужен Git с `https://git-scm.com` и доступ к репозиторию на GitHub; репозиторий приватный — доступ выдаёт владелец: Settings → Collaborators → Add people):

```
cd C:\
git clone https://github.com/WiverHome/sut.git
cd C:\sut
```

При первом `git clone` откроется окно входа в GitHub.

Вариант Б — архивом: на странице репозитория нажмите **Code** → **Download ZIP**, распакуйте, например, в `C:\sut` и перейдите в эту папку в PowerShell:

```
cd C:\sut
```

Шаг 5. Собрать и запустить

Выполните **одну** из команд в папке проекта.

С видеокартой NVIDIA (образ ~13 ГБ, скачивает ~4,5 ГБ, на проверке — 35 мин):

```
docker compose -f docker-compose.yml -f docker-compose.gpu.yml up -d --build
```

Без видеокарты (образ ~3 ГБ, скачивает ~1 ГБ):

```
docker compose up -d --build
```

В конце должно появиться `Container sut Started`.

> Если сборка оборвалась с ошибкой вроде `TLS handshake timeout` или `connection reset` — это сбой сети. Просто выполните ту же команду ещё раз: уже скачанное повторно не качается.

Шаг 6. Дождаться моделей

При первом запуске контейнер скачивает модели (~8,7 ГБ, на проверке — около 26 минут). Ход видно в журнале:

```
docker compose logs -f sut
```

Каждые 10 секунд — строка «скачано … МБ». Готово, когда появятся строки `Модель qwen-instruct:4b подключена к Ollama` и `Uvicorn running on http://0.0.0.0:8000`. Выйти из журнала — `Ctrl+C`, контейнер продолжит работать.

Если загрузку прервать или выключить ПК — после включения она продолжится сама с того же места.

Шаг 7. Открыть сайт и проверить

1. Откройте в браузере **http://127.0.0.1:8000**. В шапке справа — зелёная точка; при наведении — «Вычисления: видеокарта» или «процессор».
2. Вставьте ссылку на короткую лекцию (YouTube, RuTube, Vimeo) или загрузите файл MP4/WebM. Через 2–3 минуты появятся расшифровка, оглавление, конспект и термины.
3. Введите вопрос в строку поиска — откроется список фрагментов с таймкодами; клик по таймкоду перематывает видео.

Если в шапке написано «Без конспектов» — контейнер не достучался до Ollama: проверьте, что значок ламы есть в трее, и выполните `docker compose restart sut`.

5. Перенос лекций с другого ПК (по желанию)

Чтобы не обрабатывать лекции заново. Архив включает модели, поэтому их тоже не придётся качать.

На старом ПК (в папке проекта):

```
docker compose stop
docker compose run --rm --no-deps --entrypoint sh -v "${PWD}:/backup" sut -c "tar czf /backup/
sut-data.tgz -C /data ."
docker compose start
```

Появится файл `sut-data.tgz` в папке проекта. Перенесите его на новый ПК в папку проекта.

На новом ПК — после шага 5, до шага 6:

```
docker compose stop
docker compose run --rm --no-deps --entrypoint sh -v "${PWD}:/backup" sut -c "tar xzf /backup/
sut-data.tgz -C /data"
docker compose start
```

> В архиве лежит вход в YouTube (`youtube_cookies.txt`), если он был настроен. Передавайте архив только на свой компьютер. Перенос архивом в этой проверке не выполнялся.

6. Повседневные команды

Что сделать	Команда (в папке проекта)
Остановить	`docker compose stop`
Запустить	`docker compose start`
Журнал	`docker compose logs -f sut`
Обновить после `git pull`	команда из шага 5 (с `--build`)
Перейти на видеокарту	`docker compose -f docker-compose.yml -f docker-compose.gpu.yml up -d`
Перейти на процессор	`docker compose up -d`
Удалить всё вместе с лекциями и моделями	`docker compose down -v`

После перезагрузки ПК всё поднимается само: Docker Desktop и Ollama в автозагрузке, контейнер запускается вместе с Docker. На проверке Docker Desktop один раз не запустился сам — если сайт не открывается, запустите Docker Desktop из меню Пуск.

7. Если что-то не так

Что видно	Что делать
`could not select device driver "nvidia"`	Docker не видит видеокарту: обновите драйвер NVIDIA или запустите вариант без видеокарты.
`port is already allocated`	Порт 8000 занят. Создайте рядом с `docker-compose.yml` файл `.env` со строкой `SUT_PORT=8001`, откройте http://127.0.0.1:8001.
Сборка падает с `TLS handshake timeout`	Сбой сети — повторите команду шага 5.
YouTube: «подтвердите, что вы не робот»	Перенесите вход в YouTube с другого ПК (раздел 5) или выгрузите его из браузера — DOCKER.md, раздел «Вход в YouTube».
В шапке «Без конспектов»	Запустите Ollama, затем `docker compose restart sut`.
Нужно открыть сайт для других ПК в домашней сети	В `.env` добавьте `SUT_BIND=0.0.0.0` и выполните `docker compose up -d`. Пароля в сервисе нет — в интернет так не открывать.

8. Сайт sut.foreio.tech

Домен работает через туннель с этого ПК: на сервере только проход с паролем, вся обработка — здесь, на видеокарте. Сторож туннеля (`deploy\tunnel.ps1`, только на этом ПК, в git не попадает) запускается при входе в Windows, раз в 30 секунд проверяет туннель, Ollama и Docker Desktop и перезапускает упавшее. Если домен должен вести на другой ПК — туннель переносится туда, а здесь отключается: два ПК одновременно держать домен не могут.