КИБЕР РЫВОК 2026

СУТЬ

ТВОЙ ЛИЧНЫЙ ПОМОЩНИК

Кулакова А.М.
Лапко А.В.
Протченко А.А.
Файзуллина М.М.

Академия Инженерных Технологий и Управления

ПРОБЛЕМА

01. Большой объем

Студентам нужно быстро находить моменты в лекциях.

02. Средства

Облачные сервисы (ChatGPT, NotebookLM) требуют отправки конфиденциальных лекций в интернет и платной подписки.

03. Галлюцинации и оффлайн

Облачные LLM требуют интернета и могут выдумывать факты.

04. «Глупый» поиск

Обычный поиск по словам не понимает синонимов, а простая нарезка текста разрывает мысли лектора

ПРОДЕЛАННАЯ РАБОТА

СДЕЛАНО ПО ТЗ:

- Загрузка (MP4, YouTube, RuTube).
- Whisper (распознавание) + Таймкоды.
- Плеер Plyr (клик по тексту = перемотка).
- Конспект и структура от LLM.

СДЕЛАНО СВЕРХ ТЗ:

- Перевод RU ↔ EN (поиск между языками).
- Энциклопедия всех терминов курса.
- Chrome-расширение (боковая панель на YouTube).
- Docker (запуск одной командой).

ТЕХНО СТЕК

01. Frontend: React + Vite (SPA, две темы).

Позволяет делать быстрый интерфейс (SPA) без перезагрузок страниц.
Поддерживает две темы оформления.

02. Backend: FastAPI (асинхронный, фоновые задачи).

Асинхронный сервер. Не зависает, пока нейросеть распознает видео, а обрабатывает задачи в фоне (скачивание, распознавание, перевод).

03. База: SQLite (локально хранит текст и векторы).

Локальный файл базы данных. Не требует установки сервера, хранит текст, таймкоды и векторы для поиска.

04. ML-ядро: faster-whisper, bge-m3 + bge-reranker,Ollama + Qwen3-4BOllama + Qwen3-4B

Как мы побороли «глупый» поиск

Проблема: Векторный поиск понимает смысл, но теряет точные формулы/термины.

Наше решение (Гибридный поиск):

- Смысл: Нейросеть bge-m3 ищет фрагменты, подходящие по смыслу.
- Точность: Параллельно алгоритм BM25 ищет точные совпадения слов.
- Судья: Топ-30 лучших кусков отдается нейросети-реранкеру, которая перечитывает их вместе с вопросом и выбирает самый релевантный.

Результат:

Высокая точность даже при несовпадении формулировок. В найденном фрагменте мы подсвечиваем точные слова запроса, а таймкод ведет прямо к нужной фразе.

Умное оглавление

НАРЕЗКА НА ЧАНКИ

Делим текст на смысловые куски примерно по 30 секунд звучания.

ВЕКТОРИЗАЦИЯ

Прогоняем каждый кусок через нейросеть bge-m3, превращая текст в вектор (набор чисел, отражающий смысл).

ПОИСК ГРАНИЦ

Считаем косинусное расстояние между векторами соседних кусков. Если тема не меняется — расстояние маленькое. Если лектор резко перешел к новой теме — расстояние скачет вверх. В этих точках мы ставим границу раздела.

ГЕНЕРАЦИЯ ЗАГОЛОВКОВ

Локальная нейросеть (Qwen3) читает получившийся раздел и придумывает ему короткое, понятное название.

планы на развитие

01. Уход от зависимости от HuggingFace (свой репозиторий моделей).

02. Запуск тестового периода для сбора фидбека от студентов.

03. Привязка к Telegram-каналу (бот для поиска).

04. Доработка облачной версии (чтобы не скачивать модели).

СПАСИБО ЗА ВНИМАНИЕ