«Суть» — речь на защите

Киберрывок 2026 · 28 октября, 14:30, Яндекс Телемост · выступление ~7 минут + вопросы

Перед выступлением (за 15–20 минут)

1. Закрыть лишние программы: видеокарте нужно ~6 ГБ, памяти — побольше свободной.
2. Перезапустить контейнер, чтобы освободить видеопамять: `docker restart sut`. Подождать ~45 секунд.
3. Открыть http://127.0.0.1:8000 и сделать один пробный поиск — модели прогреются (первый запрос идёт 2–4 с, дальше 0,2 с).
4. Открыть вкладки заранее: главная «Сути», лекция Карпова №1, презентация. Подготовить ссылку на короткую лекцию для добавления (например, RuTube «2.1 лекция. Компьютерные системы», 7 мин).
5. Держать под рукой запасное видео показа — на случай, если что-то сломается.
6. В Телемосте показывать окно браузера, а не весь экран — так не видно уведомлений.

Речь по слайдам

1 · ТИТУЛ 0:30

Здравствуйте! Мы — команда [название]. Наш проект называется «Суть». Это сервис, который превращает видеолекцию в текст с оглавлением, конспектом и терминами, а главное — позволяет найти нужный момент по смыслу и сразу включить видео с этой секунды. Всё работает на одном компьютере, без платных сервисов.

2 · ПРОБЛЕМА 0:30

Знакомая ситуация: перед экзаменом нужно вспомнить одно объяснение, а лекция идёт полтора часа. Перематывать долго. Поиск по словам не помогает, если лектор сказал иначе: вы ищете «теорема Пифагора», а он говорил «квадрат гипотенузы». А сильные курсы часто на английском, хотя спросить хочется по-русски.

3 · РЕШЕНИЕ 0:40

Загружаете видео файлом или вставляете ссылку — YouTube, RuTube, VK Видео, Vimeo. «Суть» распознаёт речь, строит оглавление с таймкодами, пишет конспект и выделяет термины. Дальше можно искать по смыслу — в одной лекции или сразу по всему курсу — и задавать вопросы: ответ приходит со ссылками на нужные секунды видео. Сейчас покажу вживую.

4 · ЖИВОЙ ПОКАЗ 3:00

Переключиться на браузер с «Сутью».

1. **Главная.** «Вот курс из нескольких лекций — русские, есть часовая лекция Карпова по операционным системам».
2. **Поиск по смыслу.** *Ввести:* `одна и та же вещь выглядит по-разному с разных сторон`.
   «Первым находится притча о слепцах и слоне у Карпова, 13:42. Обратите внимание: ни одного слова из запроса в этом месте нет — поиск понял смысл». *Клик по таймкоду — видео с этой секунды.*
3. **Другой язык и опечатки.** *Ввести:* `what is an operating system`. «Английский запрос — находятся русские лекции об ОС». *Затем:* `что такое виндовс`. «В лекциях написано Windows, сервис сам понял, что ищем, — видите подпись „искал как"».
4. **Страница лекции.** «Текст идёт за видео, клик по любой фразе перематывает. Переключатель RU/EN — перевод расшифровки».
5. **Оглавление и конспект.** *Вкладка «Оглавление» → клик по разделу «История эволюции вычислительных систем»; вкладка «Конспект»; «Термины».*
6. **Вопрос-ответ.** *Вкладка «Вопрос-ответ», ввести:* `Зачем придумали мультипрограммность?`
   «Ответ за несколько секунд, и у каждого утверждения — ссылка на момент лекции, можно проверить». *Клик по ссылке.*
7. **Добавление лекции (в конце).** *Главная → вставить ссылку на короткую лекцию → «Добавить».*
   «Добавлю новую лекцию по ссылке: видно, как она скачивается и распознаётся. Через пару минут у неё будут расшифровка, оглавление и конспект». *Пока она обрабатывается — переходить к слайдам, вернуться к ней на вопросах.*

Лекция добавляется в конце показа: пока она распознаётся, чат отвечает на процессоре — 30–45 секунд вместо 7. Распознавание при этом не тормозит. Если спросят — «видеокарта занята распознаванием, поэтому чат на это время переходит на процессор».

Если показ сломался или пропала связь — без паники: «Покажу запись» и включить запасное видео. Если добавленная лекция ещё обрабатывается — «она в работе, вернёмся к ней после вопросов».

5 · КАК РАБОТАЕТ ПОИСК 0:40

Поиск идёт тремя путями. Модель bge-m3 сравнивает смысл — поэтому находится фрагмент с другими словами и даже на другом языке. Поиск по словам BM25 ловит точные термины и имена. Два списка объединяются, а лучших кандидатов перечитывает модель-«судья» — reranker. Внутри найденного 30-секундного фрагмента мы выбираем самую подходящую фразу, и видео включается ровно с неё.

6 · ОГЛАВЛЕНИЕ И КОНСПЕКТ 0:20

Оглавление строим в два шага: сначала находим места, где резко меняется смысл соседних кусков, — это границы тем. Потом локальная языковая модель Qwen даёт разделам названия, пишет тезисы, конспект и термины. Поиск доступен сразу после расшифровки, конспект догоняет за минуту-полторы.

7 · РАСШИРЕНИЕ 0:20

Есть расширение для Chrome: открываете лекцию прямо на YouTube или RuTube, а сбоку — план, текст, конспект и поиск. Клик по таймкоду перематывает видео на самом сайте. Если видео ещё не обработано — одна кнопка отправляет его в «Суть».

8 · ТЕХНОЛОГИИ 0:30

Все модели открытые и работают локально: распознавание — Whisper, поиск — bge-m3, BM25 и reranker, тексты — Qwen в Ollama. Сервер на FastAPI и SQLite, интерфейс на React с плеером Plyr. Лекции никуда не уходят с компьютера — это важно для закрытых курсов. Разворачивается одной командой в Docker — с видеокартой или без.

9 · ЦИФРЫ 0:20

Всё это — на ноутбуке с видеокартой RTX 4050 на 6 гигабайт. Поиск по курсу — около 0,2 секунды. Лекцию на час двадцать четыре минуты «Суть» расшифровала за 14 минут. Короткая лекция проходит весь путь от ссылки до конспекта за 2,7 минуты. А развернуть сервис с нуля, вместе с моделями, — около часа.

10 · ГДЕ ПОСМОТРЕТЬ 0:15

Посмотреть можно прямо сейчас на sut.foreio.tech — логин и пароль мы прислали вместе с материалами. Код на GitHub, там же подробная инструкция по запуску.

11 · ПЛАНЫ 0:20

Дальше — Telegram-бот: прислал ссылку, получил конспект. Распознавание текста со слайдов, чтобы искались формулы с экрана. Экспорт конспекта и карточек для повторения. И общие библиотеки лекций для учебных групп. Спасибо! Готовы ответить на вопросы.

Вероятные вопросы и ответы

Почему не ChatGPT или другие облачные модели?
Лекции бывают закрытыми, а платные API стоят денег и требуют интернета. Все наши модели открытые и работают на обычном ноутбуке — данные не уходят с компьютера.

Как вы проверяли качество поиска?
Набором проверочных запросов, сформулированных другими словами, чем в лекции, — как с притчей о слепцах. Смотрели, на каком месте нужный фрагмент. Когда тестеры заметили, что поиск цеплялся за слова вроде «такое», мы убрали служебные и слишком общие слова из поиска по словам и научили сервис понимать «виндовс» как Windows.

Насколько точны таймкоды?
Whisper даёт время каждой фразы с точностью до долей секунды. Мы находим самый близкий к запросу 30-секундный фрагмент, а внутри него — самую подходящую фразу, и видео включается с её начала.

А если языковая модель придумает лишнее в конспекте или ответе?
Модель отвечает только по найденным фрагментам этой лекции, и у каждого утверждения есть ссылка на момент видео — один клик, и можно проверить. Если не нашлось подходящих фрагментов, сервис так и говорит.

Работает ли без видеокарты?
Да, есть отдельный образ Docker для процессора. Поиск тогда занимает 3–4 секунды, расшифровка — медленнее, но всё работает. Мы это проверили.

Какие лекции поддерживаются?
Русский и английский, файлы MP4, WebM, MOV, MKV и ссылки на YouTube, RuTube, VK Видео, Vimeo. Можно искать по-русски в английской лекции и наоборот.

Как масштабировать на университет?
Поставить сервис на сервер с видеокартой, добавить учётные записи и группы. Для тысяч лекций — заменить SQLite на PostgreSQL с векторным поиском (pgvector) и запустить несколько обработчиков очереди. Архитектура это позволяет: обработка уже идёт отдельной очередью.

Сколько нужно ресурсов?
Модели занимают ~9 ГБ на диске, видеокарта от 6 ГБ — желательно, ОЗУ от 16 ГБ. Часовая лекция — около 0,5–1 ГБ видео.

Что было самым сложным?
Уместить распознавание, две модели поиска и языковую модель в 6 ГБ видеопамяти — пришлось выгружать модели по очереди. И YouTube: он защищается от скачивания, пришлось обновить среду выполнения JavaScript и добавить вход через браузер.

Почему сайт открыт через ваш ноутбук, а не на сервере?
Распознаванию и моделям нужна видеокарта, а на нашем сервере её нет. Поэтому сервер — только проход с паролем, а работает всё на ноутбуке. Это и есть офлайн-режим: тот же сервис можно поставить у себя одной командой.

Защита данных?
Видео и тексты не покидают компьютер. Сайт для показа закрыт паролем. Для настоящего внедрения нужны учётные записи и права — это в планах.